

SPÉCIFICATIONS TECHNIQUES : FEATURE ENGINEERING & PROTOCOLE WFO

RÉFÉRENCE : SPECS-ML-WFO-V1 **PARENT :** SAT_QHP_Vector_V1 **DATE :** 2026-01-12 **STATUT :** FROZEN

PARTIE A : DÉFINITION DU PIPELINE DE FEATURE ENGINEERING (PFE)

Cette section spécifie les algorithmes de transformation des données brutes en tenseurs d'apprentissage (X, y), ainsi que la logique mathématique de simulation de portefeuille en marge croisée (Crossed Margin) pour l'évaluation des vecteurs de trading.

1. CONSTRUCTION DES MATRICES DE FEATURES VECTORISÉES

L'objectif est de produire des matrices X (Features) et y (Targets) synchrones, nettoyées et normalisées, prêtes pour l'ingestion par les modèles ou l'optimiseur.

1.1. Normalisation Dynamique (Z-Score Roulant)

La normalisation statique (MinMax sur l'ensemble du dataset) est proscrite car elle introduit un biais d'anticipation (Look-ahead bias). Le système utilise un Z-Score calculé sur fenêtre glissante.

- **Formule :**

$$Z_t = \frac{x_t - \mu_{t-w:t-1}}{\sigma_{t-w:t-1}}$$

Où w est la fenêtre de "Lookback" (ex: 200 périodes).

- **Implémentation Vectorbt :** Utilisation de `vbt.ta.lib("STDDEV")` et `vbt.ta.lib("SMA")` pour calculer μ et σ de manière vectorisée avant d'appliquer la transformation.
- **Traitement des Outliers :** Clipping rigide des valeurs à $\pm 4\sigma$ pour éviter l'écrasement des gradients.

1.2. Alignement Multi-Timeframe (Lagging)

Les features provenant de TFs supérieurs (ex: SMA 1H) projetées sur le TF de base (ex: 5m) doivent être décalées d'une unité de leur fréquence propre pour garantir la causalité.

- **Règle de Décalage :**

$$X_{5m}[t] \leftarrow Feature_{1H}[t_{close_1H}]$$

Si t est à l'intérieur de la bougie 1H en cours, la valeur utilisée doit être celle de la bougie 1H précédente.

$$Feature_{input}[t] = Feature_{raw}.shift(1)$$

1.3. Définition des Targets (États Transitoires)

Les cibles y ne sont pas binaires mais continues pour capturer la volatilité.

- **Target Volatility-Adjusted :**

$$y_t = \frac{\ln(P_{t+n}) - \ln(P_t)}{\sigma_{vol}}$$

Où n est l'horizon de prédiction.

2. LOGIQUE DE CALCUL "CROSSED MARGIN" (SHORT/LONG)

La simulation doit modéliser un compte de trading unique partageant le collatéral entre positions Short et Long, avec gestion explicite du risque de ruine.

2.1. Équations d'État du Portefeuille

Soit E_t l'Equity (Capital Propre) au temps t , et B_t le Balance (Solde Wallet).

- **Unrealized PnL ($UPnL$) :**

$$UPnL_t = \sum_{i \in Pos} Q_i \times Side_i \times (P_{t,i} - P_{entry,i})$$

Où $Side_i = 1$ (Long) ou -1 (Short).

- **Equity Dynamique :**

$$E_t = B_t + UPnL_t$$

2.2. Ratio de Marge et Liquidation

Le système doit vectoriser la condition de liquidation pour chaque pas de temps.

- **Maintenance Margin (MM) :**

$$MM_t = \sum_{i \in Pos} |Q_i \times P_{t,i}| \times MMR_i$$

Où MMR est le Maintenance Margin Rate (ex: 0.5% pour BTC).

- **Condition de Ruine (Stop-Out) :**

$$\text{Si } E_t \leq MM_t \implies \text{LIQUIDATION FORCEE}$$

Dans Vectorbt Pro, cela se traduit par un signal de sortie prioritaire (`CloseAll`) injecté dans la matrice de signaux à l'index t .

PARTIE B : PROTOCOLE DE VALIDATION WFO (WALK-FORWARD OPTIMIZATION)

Cette section définit la méthodologie rigoureuse de validation des modèles pour éviter le sur-apprentissage (Overfitting) via une segmentation temporelle stricte.

1. PARAMÉTRAGE DES FENÊTRES GLISSANTES (IS/OOS)

L'architecture rejette la validation croisée aléatoire (K-Fold) au profit du Walk-Forward séquentiel respectant la temporalité.

1.1. Structure des Segments

- **In-Sample (IS)** : Fenêtre d'entraînement et d'optimisation des hyper-paramètres (Optuna).
- **Out-Of-Sample (OOS)** : Fenêtre de test inédite, suivant immédiatement l'IS.
- **Embargo (Purge)** : Zone tampon optionnelle entre IS et OOS pour éliminer la corrélation sérielle des features à mémoire longue.

1.2. Topologie "Rolling" vs "Anchored"

Le système privilégie le mode **Rolling** pour s'adapter aux changements de régime de marché.

- W_{len} : Longueur totale de la fenêtre (ex: 6 mois).
- R_{train} : Ratio d'entraînement (ex: 70% IS, 30% OOS).
- $Step$: Pas d'avancement (ex: 1 mois).
- **Itération k** :
 - $IS_k = [t_0 + k \cdot Step, t_0 + k \cdot Step + W_{len} \cdot R_{train}]$
 - $OOS_k = [IS_{end}, IS_{end} + W_{len} \cdot (1 - R_{train})]$

2. CRITÈRES DE FITNESS ET DÉTECTION DE DRIFT

L'évaluation de la performance ne se base pas uniquement sur le PnL, mais sur la stabilité du ratio risque/rendement.

2.1. Métriques de Fitness Composites

La fonction objective (J) maximisée par Optuna est définie comme :

$$J = \text{Sortino} \times (1 - \text{Penalite}_{dd})$$

- **Penalite Drawdown** :

$$\text{Penalite}_{dd} = \left(\frac{\text{MaxDD}}{\text{Seuil}_{tol}} \right)^2$$

Si MaxDD dépasse le seuil toléré (ex: 20%), la fitness s'effondre exponentiellement.

2.2. Seuils de Détection du Model Drift (OOS vs IS)

Le "Drift" est quantifié par la dégradation de performance entre la phase d'optimisation (IS) et la phase de test (OOS).

- **Indice de Robustesse (RI) :**

$$RI = \frac{\text{Sharpe}_{OOS}}{\text{Sharpe}_{IS}}$$

- **Critères de Rejet Automatique :**

1. **Collapse :** $RI < 0.5$ (Perte de plus de 50% de l'efficacité).
2. **Inversion :** $\text{PnL}_{OOS} < 0$ alors que $\text{PnL}_{IS} > 0$.
3. **Sur-Performance Suspecte :** $RI > 1.5$ (Indique souvent un IS mal optimisé ou un régime de marché chanceux).

3. SYNTHÈSE DES RÉSULTATS

Le résultat final n'est pas la meilleure configuration IS, mais l'agrégation ("Stitching") des courbes d'Equity OOS.

- Si la courbe concaténée OOS présente un Sharpe > 1.5 et un MaxDD $< 20\%$ sur l'ensemble de l'historique, la stratégie est validée pour déploiement (Paper Trading).

FIN DES SPÉCIFICATIONS